Agua y viñedo en la Rioja

De un pipeline de embalses que “parecia funcionar” a un sistema de datos reales, controlado y operable

Patricia Lafuente Estrada

29 de Octubre de 2026

Ficha del trabajo	
Autora	Patricia Lafuente
Entrega	30 de octubre de 2026
Repositorio	github.com/PatriciaL/tfm-embalses (público)
Plataforma	Databricks Free Edition · Unity Catalog · Databricks Apps
Fuentes	AEMET OpenData (estación 9170 Logroño) · MITECO BD-Embalses (cuenca del Ebro) · Consejo Regulador DOCa Rioja

Ficha técnica **2**
1. Resumen y objetivo **4**
2. Fuentes, arquitectura y modelado **6**
2.1 Fuentes 6
2.2 Arquitectura 7
2.3 Modelado 8
3. Método: del pipeline heredado al nuevo **9**
3.1 Diagnóstico del punto de partida 9
4. Calidad y gobierno **11**
4.1 Cuarentena: nada se descarta sin rastro 11
4.2 Controles repetibles 11
4.3 Gobierno 12
5. Operación **15**
5.1 Cómo se ejecuta 15
5.2 Incidencias y resolución 15
5.3 Historial de ejecuciones 16
6.1 Para qué sirve el dashboard 17
6.2 Resultados medidos 19
6.3 Hipótesis, no resultados 19
7. Cómo se ha trabajado con la IA **20**
Entorno, skills e instrucciones 20
Límites y verificación 21
Dónde se equivocó la IA 21
8. Justificación cuantitativa: horas y costes **22**
Qué queda demostrado 23
Qué no queda demostrado 23
Riesgos y siguientes pasos 23
Lo que me llevo 24
Anexo · Documentación y reproducibilidad **24**

1. Resumen y objetivo

- **Problema**: El pipeline se ha hecho pensando para profesionales y/ técnicos y agricultores relacionados con la elaboración y comercialización del vino. La pregunta para cada campaña siempre suele ser la misma: ¿cómo viene el agua y el calor este año comparados con añadas anteriores? Los datos existen y son públicos (reserva de los embalses, lluvia y temperatura), pero están dispersos, en formatos poco amigables y sin control de calidad. Muchas veces, cada bodega o comercializadora tiene sus propios sistemas pero no son de uso común.
- **Por qué este caso**: al estudiar dirección de empresas turísticas siempre me he sentido muy cercana al mundo de la gastronomía. Además, me gusta mucho todo lo relacionado con la enología. Dando clases, se me ocurrió utilizar la plataforma de Databricks, enseñar me da la oportunidad de utilizar y hacer cosas diferentes fuera de mi actividad profesional actual (Digital Data Analyst) creo que es una buena oportunidad para salir fuera de mi foco habitual más centrado normalmente en e-commerce.
- **Punto de partida**. El caso se construye sobre un pipeline propio de embalses en Databricks, desarrollado en agosto de 2026 como material docente. El diagnóstico inicial (sección 3) demostró que parecía funcionar, pero producía datos no verificables: cuatro de sus seis fuentes caían en silencio a ficheros de ejemplo, sin ningún tipo de error o alerta. Una inventaba lluvia de 0 mm cuando fallaba y las validaciones descartaban filas **sin dejar rastro.**
- **Objetivo**. Convertirlo en un sistema de datos real, controlado y operable, centrado en las cuatro capas que pide la guía del TFM para un proyecto propio: normalización, calidad, gobierno y operación. El resultado de negocio es un indicador de campaña vitícola (lluvia, grados-día de Winkler y reserva del Ebro) contrastado con la calificación oficial de cada añada y servido en un dashboard construido sobre una app de Databricks a través de Streamlit.
- **Alcance y límites**. Dos fuentes reales operadas a diario (AEMET y MITECO) y una de referencia mantenida a mano (DOCa). Quedan fuera las fuentes heredadas sin endpoint verificable y los modelos predictivos, sustituidos por un indicador descriptivo (decisión D-06). No hay datos personales que se hayan utilizado, la propagación de consentimiento o supresión no aplica y se declara como límite.

Resultado	Evidencia
Pipeline construido mediante arquitectura medallion con datos reales: 125.127 lecturas de 84 embalses del Ebro (1988–2026) y 9.790 días de clima de Logroño (2000–2026)	Fig. 1, 2
Cuarentena con motivo y 14 controles automáticos (9 críticos bloquean la publicación)	Fig. 3, 4
Gobierno: clasificación, etiquetas, linaje y permisos de solo lectura para el dashboard	Fig. 5–7

Resultado	Evidencia
Operación: Job diario desatendido, registro de ejecuciones y 6 incidencias reales resueltas	Fig. 8, 9 y tabla 5.2
Dashboard de negocio y de salud del pipeline	Fig. 10, 11
Uso de IA con reglas, controles y errores detectados	Sección 7

2. Fuentes, arquitectura y modelado

2.1 Fuentes

Fuente	Qué aporta	Formato y frecuencia	Papel
AEMET OpenData · estación 9170 Logroño Aeropuerto	Lluvia y temperaturas diarias	API REST con key; diaria (3–4 días de retraso)	Núcleo
MITECO · BD-Embalses (Boletín Hidrológico)	Reserva semanal de cada embalse > 5 hm^3 desde 1988; se filtra la cuenca del Ebro	ZIP con base de datos Access (10,4 MB); semanal, marcada como «sin validar»	Núcleo
Consejo Regulador DOCa Rioja	Calificación oficial de cada añada	Tabla web; anual → CSV versionado con su URL de origen	Referencia

La elección se apoyó en pruebas, no en supuestos: primero se comprobó la conectividad desde Databricks, después la descarga real y por último la lectura del contenido (figura 1). Al elegir las fuentes, el histórico llegaba al 20/10/2026, señal de actualización semanal; la carga del 28/10 lo confirmó (sección 5.3).

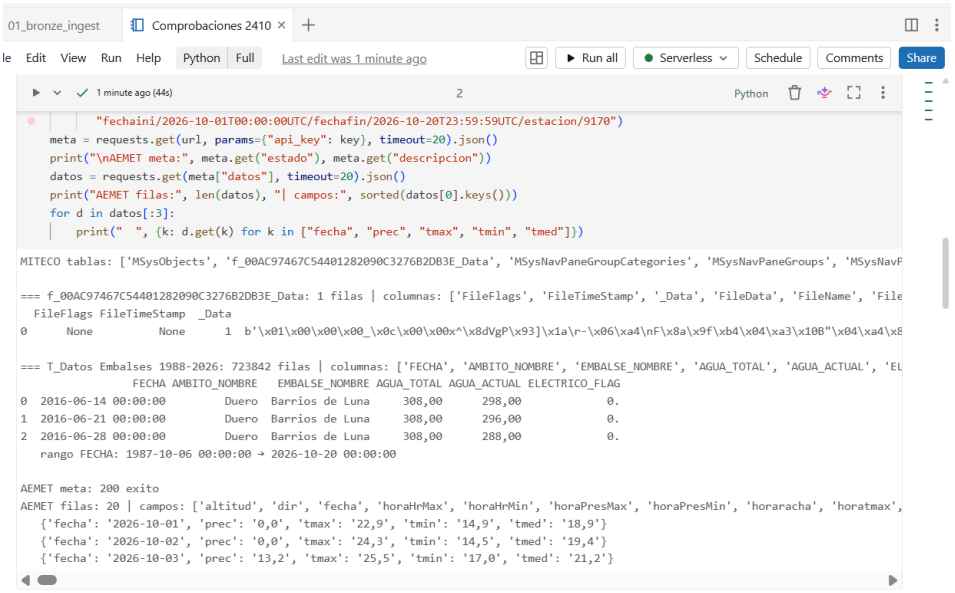


Figura 1. Primera lectura de datos reales (24/10/2026 18:30). MITECO: 723.842 filas de 1987 a 20/10/2026, con coma decimal («308,00»). AEMET 9170: lluvia y temperaturas diarias, también con coma decimal.

2.2 Arquitectura

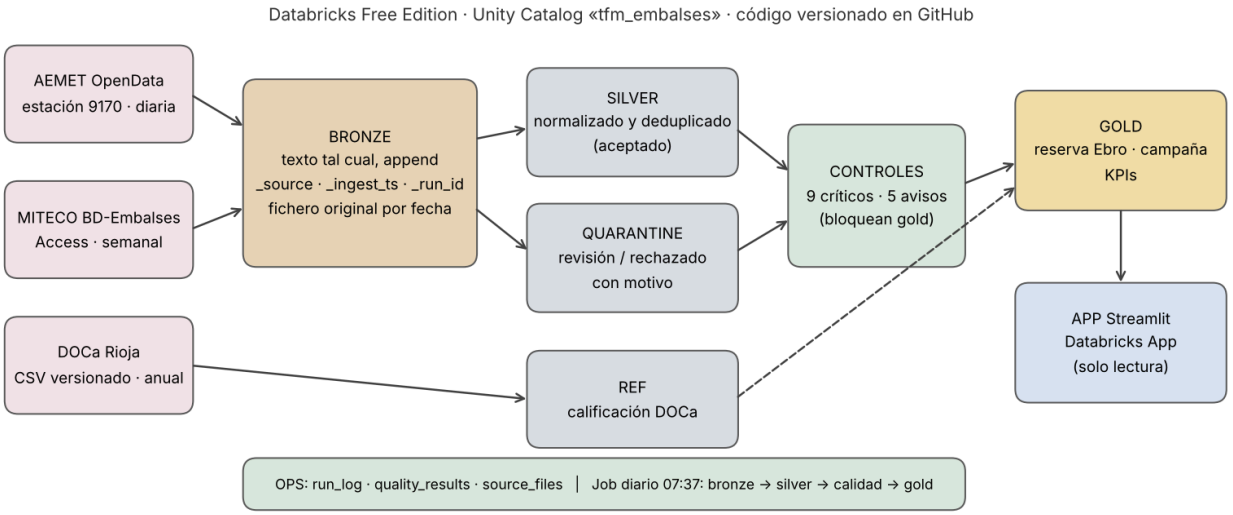


Figura 2. Arquitectura. Cada capa es un esquema de Unity Catalog con tablas Delta registradas; el Job encadena los pasos y cada uno deja rastro en ops.

2.3 Modelado

Tabla	Grano	Clave / contenido
silver.embalses_ebro	embalse × semana	embalse, fecha · volumen, capacidad, % capacidad
silver.clima_logrono	día	estacion_id, fecha · lluvia (mm), tmax, tmin, tmed
gold.reserva_ebro_semanal	semana	suma de volumen y capacidad de la cuenca · %
gold.campana_vitivinicola	campaña (1 abr–31 oct)	lluvia, Winkler = Σ max(tmed − 10 °C, 0), completitud, reserva media, calificación DOCa
gold.kpis	KPI	valor, nota, ejecución que lo generó

- **Stack**: Databricks Free Edition (serverless), Unity Catalog, Python/pandas, request, access-parser, Claude (Opus 5.5) en Claude.ai y Claude Cowork en versión escritorio
- **Rol de la IA**: la IA propuso fuentes candidatas, localizando el histórico de BD-Embalses MITECO escribió celdas de prueba de conectividad y de lectura y diagnosticó resultados.
- **Decisión y verificación humana**: la autora del TFM eligió el caso de uso, ejecutó cada prueba en Databricks y supervisó el alcance y desarrollo del trabajo. Además decidió el alcance a la vista de las salidas del modelo.

3. Método: del pipeline heredado al nuevo

3.1 Diagnóstico del punto de partida

Antes de construir nada, se evaluó el anterior código elaborado para la demo docente. Existían 9 notebooks y 5 csv de ejemplo frente a los requisitos de la guía. En este proceso de revisión, se identificaron 12 hallazgos a modo de diagnóstico. Los que más condicionan el desarrollo del trabajo se resumen a continuación:

#	Hallazgo en el pipeline heredado	Cómo se resuelve
H1	4 de las 6 fuentes utilizadas apuntaban a URLs que no existían y generaban CSV de ejemplo. La capa de bronze no distinguía el dato real del ejemplo. No se habían insertado verificaciones.	Sin fallbacks: si una fuente falla se registra y el Job se detiene. Origen (_source) en cada fila
H2	Si AEMET fallaba, se insertaba una lluvia sintética de 0,0 mm	Control crítico «sin datos sintéticos»
H4	Las filas inválidas se descartaron con un print	Estados aceptado / revisión / rechazado y tabla de cuarentena con motivo
H5	Sin tratamiento de coma decimal: «308,00» → nulo	parse_decimal_es, con prueba unitaria. Confirmado con datos reales: con el código

#	Hallazgo en el pipeline heredado	Cómo se resuelve
		heredado se habrían perdido todos los volúmenes
H6–H 7	Deduplicación arbitraria y lluvia duplicada en cada ejecución	Una fila por clave, la de la ingesta más reciente; silver se reconstruye.
H9–H 11	Índice que mezclaba cuencas, KPI mal calculado y KPIs de relleno	Todo Ebro / La Rioja; KPIs calculados desde datos y run_log

Al realizarse la comprobación de referencia oficial de la DOCa aparece un hallazgo adicional a los vistos con anterioridad: 6 de las 10 añadas del CSV original estaban mal calificadas. Se sustituyó por la tabla oficial del Consejo Regulador. Esto refuerza la conclusión del diagnóstico inicial: muchos datos del pipeline inicial no eran del todo fiables, y no existía verificación o advertencia en el pipeline.

3.2 Construcción

El sistema sigue una arquitectura medallion, un patrón habitual en plataformas de datos tipo data warehouse, data lake o lakehouse, que organiza los datos en capas de calidad creciente:

Esta arquitectura organiza los datos en capas de calidad creciente. En diferentes capas

- Bronze: guarda los datos como llegan de la fuente, en crudo, como texto sin transformaciones y con marcas de origen (fuente, fecha de carga y ejecución) para poder volver siempre al dato original.
- Silver: contiene los datos normalizados, deduplicados y validados; lo que no supera las reglas no se borra sino que pasa a una capa de cuarentena con su motivo.
- Gold: publica los indicadores listos para el consumo, en este caso el dashboard.

A estas tres capas se añaden dos esquemas de apoyo: ops, que registra cada ejecución y cada control de calidad, y ref, con la calificación oficial DOCa mantenida a mano. Los indicadores de gold se consultan desde una app de Databricks. A continuación se detalla qué hace cada capa en este caso de uso:

- Bronze: realiza la ingesta incremental, AEMET pide solo los días nuevos con 10 días de solape para recoger correcciones; MITECO solo se carga si la huella SHA256 del fichero cambia. El fichero original se conserva en un volumen, generando una carpeta por fecha de carga.
- Silver: se produce una normalización del dato, deduplicación con criterio y se reparte a silver si esta OK o se pasa a cuarentena.
- Calidad y Gold: ver secciones 4 y 6.

La lógica, se ha alojado en un módulo de funciones puras (transforms.py) con 11 pruebas unitarias que se ejecutan en local antes de cada commit.

- **Stack:** Python, pandas, PySpark, Delta Lake, pytest, Git/GitHub (Git folder en Databricks); Claude con acceso de escritura al repositorio.
- **Rol de la IA:** realizó el diagnóstico (IA-001), escribió la primera versión completa del pipeline, las pruebas y la documentación (IA-002) y completó la referencia DOCa desde la web oficial (IA-003).
- **Decisión y verificación humana:** revisión y aceptación del diagnóstico; ejecución paso a paso en la plataforma, que destapó una corrección necesaria (INC-03); decisión de aceptar la referencia DOCa sin contraste manual adicional, declarada como límite.

4. Calidad y gobierno

4.1 Cuarentena: nada se descarta sin rastro

Cada fila acaba en silver (aceptada) o en quarantine (en revisión o rechazada), siempre con su motivo. En la primera carga, el 0,34 % de las lecturas de embalses y el 0,12 % de los días de clima fueron a cuarentena.

Fuente	Aceptadas	Rechazadas (motivo)	En revisión (motivo)
Embalses del Ebro	124.701	228 (capacidad vacía o 0)	198 (volumen > capacidad)
Clima de Logroño	9.778	11 (sin temperatura media)	1 (lluvia «Acum», acumulada de varios días)



Figura 3. *Silver de embalses (24/10/2026 19:07): estados y motivos registrados en ops.run_log.*

4.2 Controles repetibles

Los 14 controles se ejecutan en cada carga y guardan su resultado en ops.quality_results. Los críticos detienen la publicación de Gold; los avisos se muestran en el dashboard.

Nivel	Controles
Crítico (9)	Unicidad de claves (2) · sin datos sintéticos (2) · % de capacidad entre 0 y 100 · silver no vacía (2) · conciliación bronze → silver + quarantine (2): 0 claves perdidas
Aviso (5)	Frescura de MITECO (≤ 14 días) y AEMET (≤ 10 días) · cuarentena ≤ 5 % (2) · variación semanal de la reserva ≤ 10 puntos

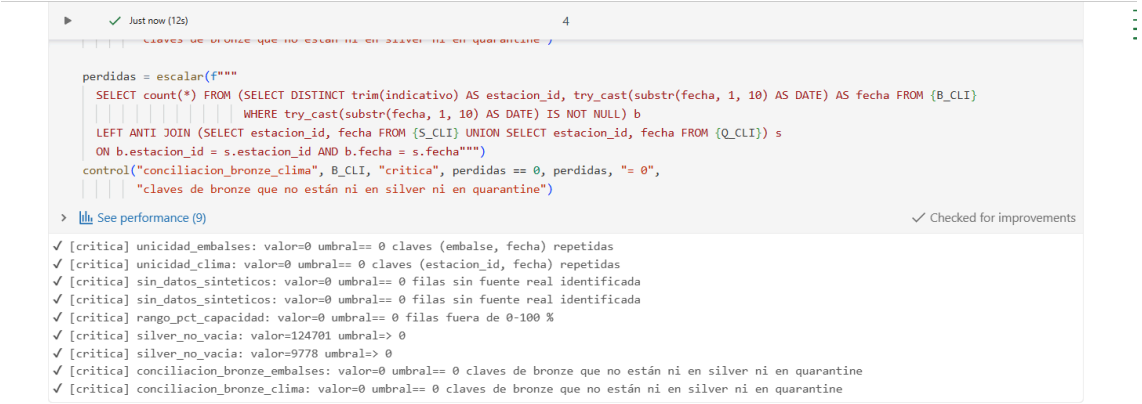


Figura 4. *Primera ejecución de los controles críticos (24/10/2026 19:11): los 9 superados, con 0 claves perdidas entre capas.*

4.3 Gobierno

- **Clasificación y documentación:** las 14 tablas tienen comentario y etiquetas (clasificación pública, sin datos personales, capa, fuente y proyecto). Las columnas clave explican su cálculo (figura 5).
- **Linaje**: Unity Catalog lo registra automáticamente donde la transformación es SQL (figura 6). Límite: en los pasos que pasan por pandas solo registra quién escribe la tabla, no de dónde viene (D-17); se compensa con la trazabilidad por fila (_source, _ingest_ts, _run_id) y con ops.run_log.
- **Exposición mínima**: el dashboard se ejecuta con su propia identidad y solo puede leer gold, ops y ref; nunca bronze ni quarantine (figura 7).
- **Secretos y datos personales**: la key de AEMET vive en un secret scope, nunca en el código. No hay datos personales; no se envió ninguno al asistente.

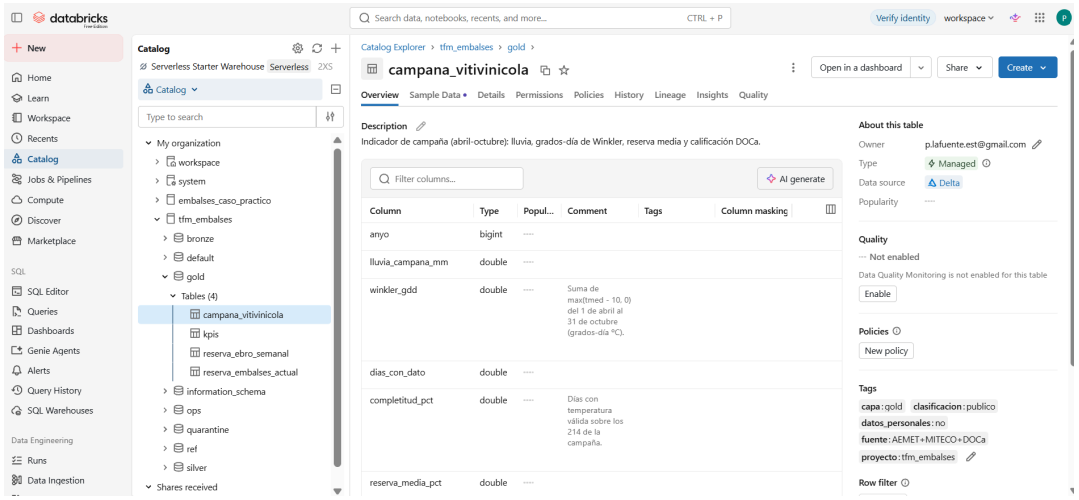


Figura 5. Catalog Explorer: descripción, comentario de columna (definición de Winkler) y etiquetas de gold.campana_vitivinicola.

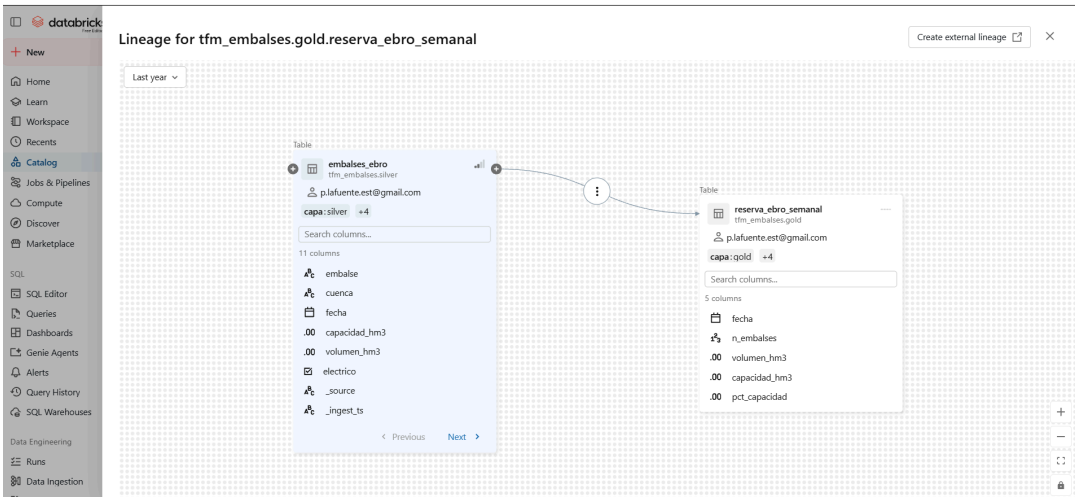


Figura 6. Linaje automático silver.embalses_ebro ➜ gold.reserva_ebro_semanal en Unity Catalog.

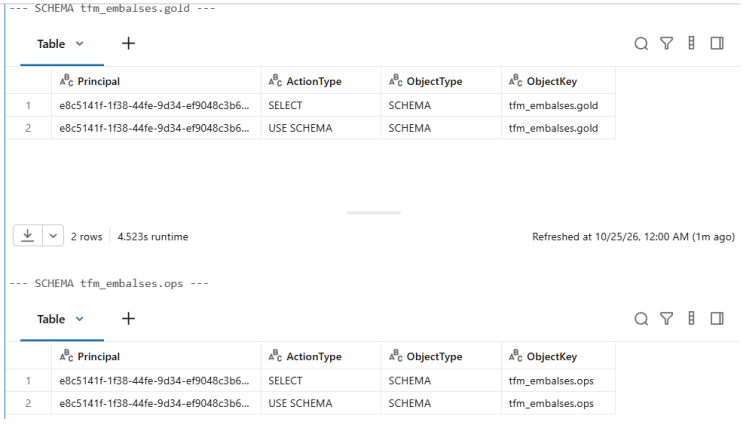


Figura 7. Permisos verificados con SHOW GRANTS (25/10/2026 00:01): la identidad de la app solo tiene USE SCHEMA y SELECT en gold y ops (y ref).

- **Stack:** Unity Catalog (tags, comentarios, linaje, GRANT), SQL, Catalog Explorer.
- **Rol de la IA:** escribió las reglas de calidad, los controles y el notebook de gobierno, y propuso la verificación con SHOW GRANTS que destapó INC-06.
- **Decisión y verificación humana**: ejecución y revisión de cada control; concesión final de permisos desde Catalog Explorer; aceptación del límite de linaje.

5. Operación

5.1 Cómo se ejecuta

El Job tfm_embalses_diario encadena bronce → silver → calidad → gold cada día a las 07:37 (Europe/Madrid), en serverless y sin intervención. Cada tarea solo se ejecuta si la anterior termina bien, y cada paso escribe su estado en ops.run_log. Se desactivó el modo *performance optimized* para no agotar la cuota diaria de Free Edition.

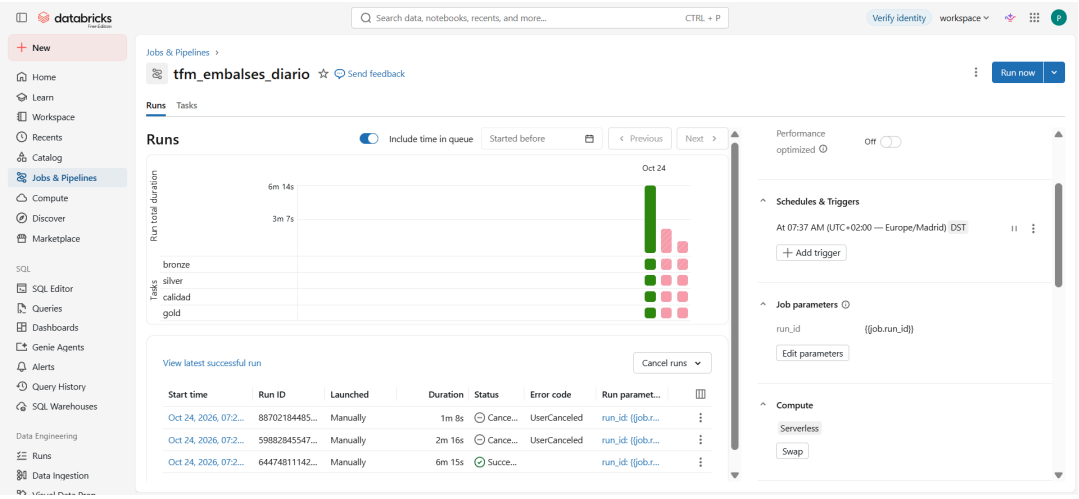


Figura 8. *Primera ejecución del Job (24/10/2026): 4 tareas en verde en 6 min 15 s. Las dos canceladas son lanzamientos duplicados detenidos a mano.*

5.2 Incidencias y resolución

#	Incidencia	Causa	Resolución
INC-01	AEMET sin datos para la estación 9170X	Indicativo erróneo heredado	Inventario oficial de AEMET: el correcto es 9170
INC-02	La descarga de MITECO se corta a 8.388.608 bytes	Límite de 8 MiB por respuesta en Free Edition	Descarga por tramos HTTP Range de 4 MiB
INC-03	Aviso de reinicio tras instalar access-parser	%pip no recarga la sesión	restartPython() tras la instalación
INC-04	GRANT: PRINCIPAL_DOES_NOT_EXIST	Se usó el nombre visible de la app	Usar un identificador

INC-05	La app no descarga el código	Repositorio privado sin credencial	Repositorio público, revisado antes: sin secretos (D-18)
INC-06	La app sin permiso USE CATALOG	El GRANT por código usó otro identificador; no dio error, pero SHOW GRANTS estaba vacío	Permisos desde Catalog Explorer, verificados con SHOW GRANTS

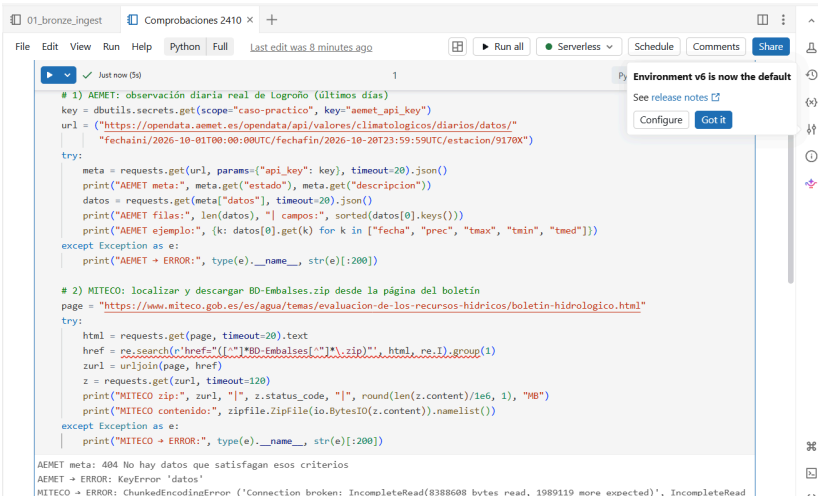


Figura 9. INC-01 e INC-02 (24/10/2026 18:12): AEMET sin datos para 9170X y la descarga de MITECO cortada exactamente a 8 MiB.

5.3 Historial de ejecuciones

Fecha	Ejecución	AEMET	MITECO	Calidad	Resultado
24/10 18:58–19:15	Manual, por pasos (carga histórica)	9.790 días	125.127 filas	14/14	OK
24/10 19:26	Job, lanzado a mano	Días nuevos	Sin cambios	14/14	OK (6 min 15 s)
25/10 07:37	Job programado (primera desatendida)	OK (último dato 21/10)	Sin cambios	14/14, 0 avisos	OK (7 min 23 s)
26/10 y 27/10 07:37	Job programado	OK	Sin cambios	14/14, 0 avisos	OK (6 min 5 s y 6 min 28 s)
28/10 07:37	Job programado · MITECO publica la semana del 27/10	OK (último dato 24/10)	Fichero nuevo: +76 lecturas	14/14, 0 avisos	OK (6 min 57 s)

La carga del 28/10 es la prueba de operación más completa. MITECO publicó la semana del 27/10 y el Job la cargó sin intervención: la huella SHA-256 del fichero cambió (tras tres días de «sin cambios»), bronze recibió de nuevo el histórico del Ebro y silver pasó de 124.701 a 124.777 lecturas. La deduplicación dejó una sola lectura por embalse y fecha (unicidad 0), la conciliación siguió a 0 y la frescura de MITECO bajó de 5 días a 1 (E-31, E-32).

- **Stack:** Databricks Jobs (serverless), Delta, ops.run_log.
- **Rol de la IA**: diseñó el registro de ejecuciones e incidencias y diagnosticó cada fallo a partir de las capturas (por ejemplo, la causa raíz de INC-06 al comparar identificadores).
- **Decisión y verificación humana**: configuración del Job en la interfaz, cancelación de duplicados y validación de cada resolución con una nueva ejecución o un SHOW GRANTS.

6. Resultados y dashboard

6.1 Para qué sirve el dashboard

El dashboard responde a dos públicos y, por eso, tiene dos pestañas:

- **Campaña y reserva (negocio)**: Para una bodega, un técnico de viñedo o la propia DOCa: en un vistazo, cómo está la reserva del Ebro frente al año anterior, cuánto ha llovido y cuánto calor ha acumulado la campaña, y dónde se sitúa respecto a todas las añadas desde 2000 con su calificación oficial. No predice la calificación: sitúa la campaña en curso frente a la historia para apoyar decisiones de riego, vendimia o comunicación.
- **Salud del pipeline (operación)**:. Para quien mantiene el sistema: ejecuciones, resultado de los 14 controles en la última carga, su evolución y los ficheros de MITECO cargados con su huella. Es la evidencia viva de que los datos de la otra pestaña están controlados.

Se implementó en Streamlit como Databricks App (D-07): el código está en el repositorio, lee en vivo las tablas gold y ops a través del SQL warehouse y se ejecuta con una identidad de solo lectura.



Figura 10. Pestaña «Campaña y reserva» (25/10/2026 00:11): KPIs y cada campaña situada por grados-día y lluvia, coloreada por su calificación DOCa.



Figura 11. Pestaña «Salud del pipeline» (25/10/2026 00:09): ejecuciones registradas y los 14 controles de la última carga, con 0 fallos.

6.2 Resultados medidos

- **Reserva del Ebro:** 44,9 % en la semana del 20/10/2026, 8 puntos por debajo de la misma semana de 2025.
- **Campaña 2026 en Logroño**: 202 mm de lluvia y 2.377 grados-día, el valor más alto de la serie desde 2000 (región V, «cálida»).
- **Lectura descriptiva de la serie**: más lluvia no implica mejor calificación. 2024 fue la campaña más lluviosa (480 mm) y se calificó «Buena»; 2016 y 2022, de las más secas, «Muy buena».

6.3 Hipótesis, no resultados

- Los grados-día de Logroño (≈ 1.950–2.380 en 2022–2026) parecen altos frente a la clasificación clásica de Rioja. Contraste: el informe de índices bioclimáticos de AEMET da a Logroño 2.748 grados-día en 2021 (1 de abril–30 de septiembre, base 10 °C, calculados con máximas y mínimas), así que el orden de magnitud es plausible. La diferencia con la referencia clásica se explica por el periodo, el método de cálculo y el calentamiento reciente; una sola estación de valle sigue sin representar toda la DOCa.

Con 26 añadas calificadas no es posible establecer una relación estadística entre clima y calificación; por eso el indicador es descriptivo.

- **Stack:** Streamlit, Altair, databricks-sql-connector, Databricks Apps, SQL warehouse serverless.
- **Rol de la IA**: escribió la app y su configuración, y revisó la app desplegada en el navegador integrado (solo lectura).
- **Decisión y verificación humana**: creación y despliegue de la app, concesión de permisos y comprobación de que los KPIs coinciden con gold.kpis (E-15).

7. Cómo se ha trabajado con la IA

Los recuadros de cada sección dicen qué hizo la IA en ese paso. Esta sección explica con qué entorno, con qué reglas y con qué controles se trabajó; el detalle está en docs/uso_ia.md y en el registro de uso de IA (IA-001 a IA-008).

Entorno, skills e instrucciones

Pieza	Qué aporta al trabajo
Claude Opus 5.5 (Anthropic), en la app de Claude en modo agente	Ejecuta tareas de varios pasos en un espacio de trabajo en la nube: escribe y prueba código, genera documentos y hace commits
Proyecto de Claude con la guía, el diagnóstico, las decisiones y las evidencias	Contexto persistente: cada sesión parte de los requisitos y de lo ya decidido
Conectores: GitHub, Google Drive, búsqueda web y navegador integrado	Repositorio, documentos de trabajo, verificación de fuentes públicas y revisión de la app (solo lectura)
Skills de la plataforma: docx y navegador integrado	Instrucciones empaquetadas para generar esta memoria en Word y para usar el navegador con sus límites
Skill propia: pipeline-datos-controlado	El método de este trabajo empaquetado para reutilizarlo: principios, fases, controles, notas de Databricks Free Edition y checklist (carpeta skills/ del repositorio)
CLAUDE.md del repositorio	Las reglas que la IA cumple siempre: sin datos sintéticos ni respaldos silenciosos, trazabilidad por fila, nada se descarta sin rastro, pruebas antes de cada commit, sin secretos y registro de cada cambio con IA

Las tres primeras reglas de CLAUDE.md traducen los hallazgos del diagnóstico: son justo los errores que el pipeline heredado cometía y que una IA podría reintroducir sin darse cuenta. Los encargos siguieron las cinco piezas de la guía (§8): una tarea concreta cada vez, el contexto del proyecto, los límites de CLAUDE.md, un formato de salida definido y una verificación asociada. Los prompts clave se guardan literales en docs/uso_ia.md.

Límites y verificación

- La IA no ejecuta en Databricks ni maneja credenciales: la autora ejecuta cada celda, crea el Job, la app y los permisos, y aporta la captura. Se dejó de automatizar la consola desde el navegador al aparecer el aviso de control automatizado.

- Cada salida tiene su comprobación: pruebas unitarias, ejecución real con captura fechada, los 14 controles de calidad, contraste con fuente oficial (DOCa, AEMET) y, para los comentarios de los notebooks, comparación del árbol sintáctico para asegurar que el código no cambió.

Dónde se equivocó la IA

Caso	Qué pasó	Cómo se detectó
Permisos de la app (INC-06)	El GRANT propuesto se ejecutó sin error, pero sin efecto	SHOW GRANTS vacío; corregido desde Catalog Explorer
Límite de 8 MiB (INC-02) y reinicio tras %pip (INC-03)	Límites de la plataforma no anticipados	Errores en la primera ejecución real
Repositorio privado (INC-05)	Se asumió que la app podría leerlo	Error «no credential» al desplegar
Valores de Winkler	Más altos que las referencias clásicas de Rioja	Contraste con un informe de AEMET antes de aceptarlos

- **Stack**: Claude Opus 5.5 en la app de Claude; proyecto de Claude; conectores de GitHub y Google Drive; búsqueda web; navegador integrado; skills docx y navegador.
- **Rol de la IA**: planificar las fases, escribir código y documentación, verificar fuentes públicas y proponer soluciones a las incidencias.
- **Decisión y verificación humana**: elegir el caso, el alcance y las fuentes; tomar las decisiones D-01 a D-18; ejecutar en la plataforma; detectar las incidencias y aceptar o rechazar cada salida con su evidencia.

8. Justificación cuantitativa: horas y costes

- **Tarea comparada:** llevar un pipeline heredado de una fuente pública a producción controlada (diagnóstico, fuentes reales, normalización, calidad, gobierno, operación, dashboard y documentación). Criterio de resultado correcto: los 14 controles superados, el Job operando y el dashboard con datos reales.

Bloque	Sin IA (estimación)	Con IA: ejecución + revisión humana
Diagnóstico del código heredado	2,5 h	0,3 h
Búsqueda y pruebas de fuentes reales	3 h	0,8 h
Pipeline, pruebas y normalización	14 h	1,5 h
Calidad y controles	4 h	0,5 h
Gobierno y permisos	2 h	1 h
Dashboard y despliegue	6 h	1,5 h

Bloque	Sin IA (estimación)	Con IA: ejecución + revisión humana
Registros, evidencias y documentación	4,5 h	1,5 h
Memoria, comentarios de notebooks, documentación del uso de IA y skill	10 h	1,2 h
Seguimiento de la operación (comprobar ejecuciones y registrar evidencias)	0,7 h	0,7 h
Total	46,7 h	9,0 h (24/10 17:07 → 25/10 01:10, más 25/10 08:03–08:20 y 09:32–10:15)

Origen de las cifras. Las horas con IA salen de las marcas de tiempo de las sesiones de trabajo; su reparto por bloque es aproximado e incluye la revisión humana (ejecutar, comprobar, decidir). El seguimiento de la operación cuesta lo mismo en los dos modos, porque lo hace la autora. La revisión y redacción final de la memoria (5 h) es trabajo de la autora y cuenta íntegra en el modo con IA La columna sin IA es una estimación de la autora para una profesional con experiencia en el stack: no hay línea base observada. Para confirmarla habría que repetir una tarea equivalente sin asistente.

Concepto	Valor	Tipo
Horas ahorradas por ejecución (47,2 − 14,5))	32,7 h	Estimación
Tarifa horaria	45 €/h	Supuesto declarado
Coste incremental de IA y herramientas por ejecución	≃ 22 € (un mes de Claude Pro: 20 USD + IVA; Databricks Free Edition y GitHub: 0 €)	Medido: plan usado; importe según factura
Ejecuciones al año (nuevas fuentes o casos equivalentes)	4	Supuesto
Beneficio neto anual estimado	(32,7 × 45 − 22) × 4 ≃ 5.798 €	Estimación

Límites. El ahorro de tiempo es más sólido que el monetario, que depende de la tarifa y de la frecuencia supuestas. El ahorro no es gratuito: hubo 6 incidencias que la IA no anticipó y que exigieron ejecución y criterio humano, y su propia propuesta de permisos por código falló en silencio (INC-06). En plataformas de pago habría que sumar el coste de cómputo, aquí nulo por usar Free Edition.

9. Conclusiones y límites

Qué queda demostrado

- Que un pipeline que «funcionaba» puede estar produciendo datos no verificables, y que diagnosticarlo con evidencia (hallazgos confirmados con datos reales) es el primer paso de cualquier proyecto de datos.

- Un flujo de datos reales con origen trazable por fila, cuarentena con motivo, 14 controles repetibles que bloquean la publicación, gobierno con exposición mínima y operación diaria registrada.
- Un uso de IA trazable y con reglas: un CLAUDE.md que fija lo que la IA no puede hacer, 8 entradas en el registro de IA con su verificación y la decisión humana explícita, y los casos en que la IA se equivocó, detectados y corregidos (sección 7).

Qué no queda demostrado

- La línea base manual es estimada, no medida.
- La relación entre clima y calificación DOCa: el indicador es descriptivo.
- El linaje completo entre tablas en los pasos con pandas (D-17).
- Una sola estación meteorológica representa la DOCa, y la añada 2000 procede de una fuente secundaria.

Riesgos y siguientes pasos

- MITECO publica sus datos «sin validar»: pueden revisarse hacia atrás. El pipeline ya conserva cada versión del fichero y se queda con la última; el siguiente paso sería medir cuántos valores cambian entre versiones.
- Reescribir en Spark los pasos con pandas para recuperar el linaje completo, añadir más estaciones (Haro, Rioja Alta) y alertas por correo cuando falle un control crítico.
- Con más tiempo, añadiría más fuentes de datos y capas de predicción, por ejemplo para estimar la demanda de vino o la capacidad de las bodegas. Los modelos se descartaron en este trabajo (D-06) porque no había datos suficientes para entrenarlos con garantías; más fuentes son la condición para recuperarlos.

Lo que me llevo

El pipeline de agosto lo monté yo como material docente y, aunque no era del todo correcto, me dio la oportunidad de “cacharrear” con Databricks. No soy una profesional senior de data engineering y es normal tener errores. Para mí, detectar el fallo ha sido lo más valioso: me ha permitido mejorarlo y descubrir piezas que no tenía en el radar, como la capa de gobierno o desplegar el dashboard en Streamlit directamente en Databricks. Además, he aprendido a usar la plataforma, y a explorarla, ya que cuando tengo dudas de donde se encuentran las cosas, el asistente funciona como un tutor. Esto me permite desarrollar trabajos como el expuesto, pudiendo aprender haciendo pero sin tener que estar preguntando a un perfil senior.

Lo más difícil de trabajar con IA ha sido no dar por sentadas sus respuestas. Cuesta no creerse directamente que todo es verídico, porque no se nos enseña a cuestionarla. Por eso este trabajo registra cada verificación y también los casos en que la IA se equivocó (sección 7).

En el día a día, usada como copiloto, me permite aprender cosas nuevas sin tener experiencia previa en ellas y profundizar, aunque no sea a nivel profesional. Creo que es una herramienta muy potente, siempre que se trabaje con reglas y comprobando lo que propone.

Anexo · Documentación y reproducibilidad

Elemento	Dónde
Código, pruebas y notebooks	github.com/PatriciaL/tfm-embalses (pipeline/, tests/, app/)
Reproducir desde cero	README.md del repositorio (5 pasos; las pruebas se ejecutan con pytest)
Diagnóstico del pipeline heredado	docs/diagnostico.md
Registro de decisiones (D-01 a D-18)	docs/decisiones.md
Índice de evidencias e incidencias (E-01 a E-32, INC-01 a INC-06)	docs/evidencias.md
Registro de uso de IA (IA-001 a IA-008)	docs/ai_log.md
Entorno de IA, skills, reglas y prompts clave	docs/uso_ia.md y CLAUDE.md
Skill reutilizable del método	skills/pipeline-datos-controlado/SKILL.md
Definición del Job	jobs/job_tfm_embalses.md