Anexos · Agua y viñedo en La Rioja

TFM · Jxpert IA Aplicada · Track 9 IA aplicada a Data Management
Patricia Lafuente Estrada · octubre de 2026

Registros del proyecto, tal como están en el repositorio `github.com/PatriciaL/tfm-embalses` (carpeta `docs/`).

1. A · Registro de uso de IA (`docs/ai_log.md`)
2. B · Cómo se ha trabajado con la IA (`docs/uso_ia.md`)
3. C · Registro de decisiones (`docs/decisiones.md`)
4. D · Evidencias e incidencias (`docs/evidencias.md`)
5. E · Diagnóstico del pipeline heredado (`docs/diagnostico.md`)

A · Registro de uso de IA · TFM Embalses

Campos según la guía del TFM (§7). Solo se registran los intercambios que afectaron a decisiones, código, modelo, reglas o resultados.

IA-001 · Diagnóstico del pipeline heredado

Campo	Contenido
Fecha y tarea	24/10/2026, 17:35–17:46. Diagnosticar el estado de los notebooks del caso de embalses (agosto de 2026) frente a los requisitos del TFM.
Herramienta o modelo	Claude (Claude Opus 5.5) en claude.ai, proyecto "JAKALA IA".
Entrada relevante	Export ZIP de la carpeta `kinedrik_caso_practico_embalses` (9 notebooks y 5 CSV de ejemplo) y la guía del TFM. Petición: inventariar qué hace cada notebook, qué fuentes son reales o de ejemplo, qué tablas genera, qué funciona y qué falta frente a la guía. Sin secretos: la API key de AEMET está en un secret scope y no aparece en el código. Sin datos personales.
Salida utilizada	Documento `diagnostico.md`, con 12 hallazgos en fuentes, silver, gold y modelos, lo aprovechable, una fuente real candidata (histórico BD-Embalses de MITECO) y una propuesta de alcance. Se incorpora completo como documento de trabajo y fuente de las secciones 2–3 de la memoria.
Verificación	Hecha: revisión humana del documento (24/10, 17:49). Pendiente: (a) confirmar en la primera ejecución los hallazgos marcados "a verificar", en especial el 1 (fallback a CSV) y el 5 (coma decimal), con captura de los mensajes del log; (b) comprobar la estructura real del Excel de MITECO en F3.
Decisión humana	Aceptado el diagnóstico completo como base del alcance. La propuesta de alcance (§6) queda pendiente de decisión en F1.

Para el ROI: diagnóstico asistido de unos 15 minutos de IA más unos 5 de revisión humana. La línea base manual está sin medir: estimación de 2–3 horas para leer 9 notebooks y cruzarlos con la guía (*estimación, a declarar como supuesto*).

IA-002 · Primera versión del pipeline nuevo

Campo	Contenido
Fecha y tarea	24/10/2026, 18:40–19:10. Escribir la primera versión del pipeline con fuentes reales (AEMET 9170 y MITECO Ebro), cuarentena, controles de calidad, gold del indicador de campaña y operación registrada.
Herramienta o modelo	Claude (Claude Opus 5.5) en claude.ai, con acceso de escritura al repositorio `PatriciaL/tfm-embalses`.
Entrada relevante	Diagnóstico F0, decisiones D-01 a D-13 y resultados reales de las pruebas de conectividad y lectura (E-01 a E-05). Sin secretos ni datos personales.
Salida utilizada	Notebooks `00`–`04`, módulo `transforms.py` (lógica pura) y `common.py` (configuración y registro), 11 pruebas unitarias, README, CLAUDE.md, definición del Job y CSV de referencia DOCa con 3 añadas (2021–2023) tomadas de prensa y pendientes de verificar en la fuente oficial.
Verificación	Hecha: las 11 pruebas pasan en local (`pytest`), cubriendo coma decimal, `Ip`, control de esquema, estados de calidad, deduplicación, idempotencia y Winkler. Primera ejecución completa en Databricks el 24/10 (18:58–19:15): bronze, silver, 14 controles de calidad superados y gold publicado (evidencias E-06 a E-15). Única corrección necesaria: reinicio de Python tras `%pip` (INC-03).
Decisión humana	Aceptado tras la ejecución en la plataforma. Pendiente de contrastar con bibliografía que los valores de Winkler de Logroño (≈1.950–2.380 en 2022–2026) son coherentes.

Hallazgo lateral: las calificaciones DOCa del CSV de ejemplo heredado no coinciden con la tabla oficial del Consejo Regulador: **6 de sus 10 añadas (2015–2024) son erróneas** (2016, 2017, 2018, 2019, 2021 y 2022). Refuerza el hallazgo 1: los datos de ejemplo eran inventados.

IA-003 · Calificaciones oficiales DOCa Rioja

Campo	Contenido
Fecha y tarea	24/10/2026, 18:55. Completar `ref/doca_calificaciones.csv` con la calificación oficial de cada añada.
Herramienta o modelo	Claude (Claude Opus 5.5) con búsqueda web.
Entrada relevante	Petición de buscar la tabla oficial del Consejo Regulador. Sin datos personales.
Salida utilizada	2001–2025 desde la web oficial (riojawine.com/es/doca-rioja/anadas/); 2000 desde una fuente secundaria (anadas-do.com), marcada con `tipo_fuente = secundaria` porque la web oficial no la mostraba en la primera página.
Verificación	Automática: los datos 2001–2025 se leyeron directamente de la página oficial; cada fila conserva su URL de origen para poder auditarla. Sin contraste manual adicional.
Decisión humana	24/10, 18:54: aceptado tal cual por prioridad de tiempo. Límite declarado: la añada 2000 procede de una fuente secundaria.

IA-004 · Gobierno y dashboard

Campo	Contenido
Fecha y tarea	24–25/10/2026, 19:35–00:06. Notebook de gobierno (comentarios, etiquetas, permisos) y dashboard Streamlit como Databricks App.
Herramienta o modelo	Claude (Claude Opus 5.5) en claude.ai, con acceso de escritura al repositorio y al navegador integrado (solo lectura de la app).
Entrada relevante	Decisiones D-07 y D-16, tablas gold y ops ya publicadas. Sin secretos ni datos personales.
Salida utilizada	`pipeline/05_governance.py`, `app/app.py`, `app/app.yaml`, `app/requirements.txt` y `app/README.md`.
Verificación	Gobierno: 14 tablas con comentario y etiquetas (E-18, E-19), linaje revisado con un límite detectado (E-20, E-21). Permisos: el GRANT por código no dejó permiso efectivo (INC-06); se verificó con `SHOW GRANTS` y se corrigió desde Catalog Explorer (E-25, E-26). App: despliegue correcto tras hacer público el repo (INC-05, E-24); revisión en navegador el 25/10 00:06: KPIs, gráfico de campañas frente a DOCa, reserva del Ebro y pestaña de salud (4 ejecuciones OK, 14 controles, 0 fallos) cargan con datos reales.
Decisión humana	Aceptado. Mejora menor pendiente: la tabla de ejecuciones muestra horas en UTC.

IA-005 · Borrador de la memoria

Campo	Contenido
Fecha y tarea	25/10/2026, 00:15–00:45. Redactar la memoria técnica (máx. 15 páginas) a partir de los registros del proyecto.
Herramienta o modelo	Claude (Claude Opus 5.5) en claude.ai; documento Word generado con docx-js, diagrama de arquitectura con matplotlib.
Entrada relevante	Guía del TFM, diagnóstico, decisiones, evidencias (E-01 a E-26), incidencias, registro de IA y dos capturas de la app aportadas por la autora. Petición de la autora: explicar para qué sirve el dashboard e incluir el stack y el rol de la IA en cada sección.
Salida utilizada	Borrador de 11 páginas con 11 figuras con pie, siguiendo la estructura de la guía (§5); recuadro "Stack · Rol de la IA · Decisión humana" en cada sección. Las horas sin IA son una estimación declarada y el coste de la suscripción es un supuesto pendiente de confirmar.
Verificación	Renderizado a PDF y revisión visual de todas las páginas. Pendiente: revisión de contenido por la autora y completar el historial de ejecuciones (tabla 5.3) con las cargas del 25, 27–28 y 29/10.
Decisión humana	Pendiente.

IA-006 · Comentarios didácticos en los notebooks

Campo	Contenido
Fecha y tarea	25/10/2026, 00:35–00:50. Comentar los notebooks 00–05 explicando qué hace cada celda en lenguaje sencillo, para que la autora pueda entender y defender el código.
Herramienta o modelo	Claude (Claude Opus 5.5) en la app de Claude, con acceso de escritura al repositorio.
Entrada relevante	Los seis notebooks del pipeline y la petición de la autora: "comentar los notebooks explicando qué hace cada celda, también de forma fácil". Sin secretos ni datos personales.
Salida utilizada	Una celda Markdown "Celda N · …" antes de cada celda de código (qué hace, paso a paso y por qué) y comentarios en línea en los pasos clave. Resumen "En una frase" al inicio de cada notebook.
Verificación	Automática: comparación del árbol sintáctico (AST) de cada notebook antes y después; el código ejecutable es idéntico en los seis, solo cambian los comentarios. Las 11 pruebas pasan (`pytest`).
Decisión humana	Pendiente: revisión de la autora tras hacer Pull en Databricks.

IA-007 · Documentación del entorno de IA y sección de la memoria

Campo	Contenido
Fecha y tarea	25/10/2026, 00:50–01:10. Documentar con qué entorno, skills, reglas y controles se ha trabajado con la IA, y hacerlo visible en la memoria (el máster es de AI Fluency).
Herramienta o modelo	Claude (Claude Opus 5.5) en la app de Claude, con acceso al repositorio, al proyecto de Claude y a búsqueda web.
Entrada relevante	Petición de la autora: documentar las skills y el resto del entorno. Registro de IA, decisiones, incidencias y los prompts de la autora en la sesión. Sin secretos ni datos personales.
Salida utilizada	`docs/uso_ia.md` (entorno, skills, reglas de `CLAUDE.md`, prompts clave literales, límites, técnicas de verificación, errores de la IA y reparto de papeles) y nueva sección 7 de la memoria «Cómo se ha trabajado con la IA»; las secciones siguientes pasan a ser 8 y 9. Se actualiza el apartado 6.3 con el contraste de Winkler: el informe de índices bioclimáticos de AEMET da a Logroño 2.748 grados-día en 2021 (1 abr–30 sep, base 10 ºC), lo que hace plausibles los valores obtenidos.
Verificación	Cada caso de error citado se comprobó contra `evidencias.md` (INC-02, INC-03, INC-05, INC-06). Memoria regenerada y revisada visualmente: 12 páginas. Fuente del contraste: repositorio.aemet.es (Indices_bioclimaticos_CAL2024.pdf).
Decisión humana	Pendiente: revisión de la autora (en especial, que los prompts citados la representan). Resuelve la verificación pendiente de Winkler de IA-002.

IA-008 · Skill reutilizable `pipeline-datos-controlado`

Campo	Contenido
Fecha y tarea	25/10/2026, 08:05–08:20. Convertir el método del TFM en una skill reutilizable.
Herramienta o modelo	Claude (Claude Opus 5.5) en la app de Claude; propuesta de skill para añadirla a la cuenta de la autora.
Entrada relevante	Petición de la autora («sí, hazla») tras proponer una skill propia. Contexto: `CLAUDE.md`, notebooks, decisiones, incidencias y guía del TFM. Sin secretos ni datos personales.
Salida utilizada	`skills/pipeline-datos-controlado/SKILL.md`: principios, 9 fases, catálogo de controles, trabajo con IA, notas de Databricks Free Edition y checklist. Se añade a `docs/uso_ia.md` (§2 y §8) y a la sección 7 de la memoria.
Verificación	Cada nota de plataforma corresponde a una incidencia o decisión registrada (INC-02, INC-03, INC-05, INC-06, D-17); los controles coinciden con los del notebook 03. Pendiente: probarla en un caso nuevo.
Decisión humana	Pendiente: guardarla desde la tarjeta de propuesta y revisarla.

IA-009 · Revisión de la memoria: ROI y voz de la autora

Campo	Contenido
Fecha y tarea	25/10/2026, 10:10–19:50. Cerrar los supuestos del ROI e incorporar la voz de la autora en la introducción y las conclusiones.
Herramienta o modelo	Claude (Claude Opus 5.5) en la app de Claude, con búsqueda web.
Entrada relevante	Respuestas de la autora: plan Claude Pro, sumar las sesiones posteriores a las horas con IA, tarifa de 45 €/h, y sus respuestas a cinco preguntas sobre motivación, aprendizajes, uso de la IA y siguientes pasos. Sin datos personales sensibles.
Salida utilizada	Sección 8: coste de herramienta ≈ 22 €/mes (Claude Pro, 20 USD + IVA), horas con IA 9,0 h frente a 46,7 h estimadas sin IA, beneficio neto ≈ 6.698 €/año. Sección 1: párrafo «Por qué este caso». Sección 9: siguiente paso de predicción y apartado «Lo que me llevo», redactados en primera persona a partir de las respuestas literales de la autora. Memoria: 13 páginas.
Verificación	Precio de Claude Pro contrastado en el centro de ayuda de Anthropic (20 USD/mes más impuestos; el importe en euros se confirma con la factura). Aritmética del ROI recalculada en código. Revisión visual del PDF.
Decisión humana	Pendiente: la autora revisa que los textos en primera persona la representan.

B · Cómo se ha trabajado con la IA · TFM Embalses

Complementa el registro de uso de IA (`ai_log.md`, IA-001 a IA-008). El registro dice **qué** se hizo con IA en cada paso; este documento dice **con qué entorno, con qué reglas y con qué controles** se trabajó.

---

1. Entorno

Pieza	Qué es	Para qué se usó
Modelo	Claude Opus 5.5 (Anthropic)	Todo el trabajo asistido
Superficie	App de Claude, en modo agente: la IA ejecuta tareas de varios pasos en un espacio de trabajo en la nube (terminal Linux, Python, Node)	Escribir y probar código, generar documentos, hacer commits
Proyecto de Claude "JAKALA IA"	Carpeta persistente con documentos de contexto (`master-ia/`: guía del TFM, diagnóstico, decisiones, evidencias, registro de IA)	Que cada sesión parta de los requisitos y de las decisiones ya tomadas, sin volver a explicarlas
Conector GitHub	Acceso de escritura al repositorio `PatriciaL/tfm-embalses`	Commits y push del código y la documentación
Conector Google Drive	Lectura y escritura en "JAKALA IA MASTER"	Leer la guía del TFM y publicar documentos de trabajo
Búsqueda web	Búsqueda y lectura de páginas públicas	Verificar fuentes (AEMET, MITECO), obtener las calificaciones oficiales DOCa y contrastar valores de Winkler
Navegador integrado	Panel de navegador en el ordenador de la autora	Revisar la app desplegada (solo lectura)

2. Skills e instrucciones

Una *skill* es un paquete de instrucciones que la IA carga para hacer bien un tipo de tarea concreto. Se distinguen las skills de la plataforma de las instrucciones propias del proyecto.

Tipo	Elemento	Qué aporta
Skill de la plataforma	**docx** (documentos Word)	Generar la memoria con estilos, tablas, figuras numeradas y pies de página correctos
Skill de la plataforma	**Navegador integrado**	Uso del panel de navegador, sus permisos y límites
Skill propia	**`pipeline-datos-controlado`** (`skills/`)	El método de este TFM convertido en skill reutilizable: principios, fases, controles, notas de Databricks Free Edition y checklist. Ver §8
Instrucciones del proyecto	**`CLAUDE.md`** del repositorio	Las reglas que la IA debe cumplir siempre en este repo (ver abajo)
Contexto del proyecto	**`tfm-requisitos.md`**	La guía del TFM convertida a Markdown: la IA comprueba cada entregable contra ella
Contexto del proyecto	**`decisiones.md`**, **`evidencias.md`**, **`ai_log.md`**	Memoria de trabajo: qué se decidió, qué se probó y qué falta

Reglas de `CLAUDE.md` (son la "política" del proyecto para la IA):

1. Nunca introducir datos de ejemplo, sintéticos ni *fallbacks* silenciosos: si una fuente falla, se registra y se detiene.
2. Toda fila de bronze lleva `_source`, `_ingest_ts` y `_run_id`.
3. Ninguna fila se descarta sin rastro: va a silver o a quarantine con motivo.
4. La lógica de transformación va en `transforms.py` con su prueba; `pytest` antes de cada commit.
5. Nada de secretos en el repositorio (la API key está en el secret scope).
6. Cada cambio relevante hecho con IA se registra en `ai_log.md`.

Las reglas 1 a 3 responden directamente a los hallazgos del diagnóstico del pipeline heredado: son errores que una IA (o una persona) podría reintroducir sin darse cuenta.

3. Prompts clave

La guía (§8) pide guardar los prompts importantes. Se recogen literales, con la entrada del registro a la que dieron lugar.

Prompt de la autora (literal)	Qué desencadenó	Regis
"te leas el documento y me digas como vamos a organizar el workspace para luego pasar al faseado"	Lectura de la guía y propuesta de organización y fases	—
"tenemos que revisar el trabajo hecho ahora porque no se que ha salido de aqui […] quiero que ahora seas un planificador y hagamos las fases del TFM antes de empezar a trabajar"	Diagnóstico del pipeline heredado antes de escribir código	IA-001
"podemos hacer una alternativa? me gustaria que fuera relacionado con vino"	Sustituir los modelos por el indicador de campaña vitícola (D-06)	—
"busca la salida del consejo regulador y listo la añades donde toque"	Calificaciones oficiales DOCa desde la web del Consejo Regulador	IA-003
"hay que explicar en la memoria para que sirve el dashboard e incluir stack y rol de la IA en cada una"	Recuadro "Stack · Rol de la IA · Decisión humana" en cada sección	IA-005

Prompt de la autora (literal)	Qué desencadenó	Regis
"se sincero […] crees que el trabajo tiene calidad?"	Revisión crítica: riesgos de la defensa, valores de Winkler a contrastar	—
"necesito que comentes los notebooks explicando que hace cada celda tambien de forma facil"	Comentarios didácticos sin tocar el código	IA-006

Patrón seguido en los encargos, alineado con las cinco piezas de la guía (§8): **tarea concreta** (una fase cada vez), **contexto mínimo** (los documentos del proyecto), **límites** (las reglas de `CLAUDE.md`), **formato de salida** (notebook, documento o tabla de registro) y **verificación** (cada entrega llega con su prueba o su evidencia).

4. Límites puestos a la IA

Límite	Por qué
La IA **no ejecuta nada en Databricks**: la autora ejecuta cada celda y el Job, y aporta la captura	La ejecución real y su evidencia quedan bajo control humano
La IA **no introduce credenciales** ni accede a la API key	Los secretos solo existen en el secret scope
Se dejó de automatizar la consola de Databricks desde el navegador al aparecer el aviso de control automatizado	No operar una plataforma de forma automatizada sin permiso explícito
Navegador solo de lectura sobre la app	Revisar sin modificar
Decisiones de alcance, fuentes y diseño: siempre de la autora (D-01 a D-18)	La IA propone; la autora decide

5. Cómo se verificó lo que hizo la IA

Técnica	Dónde se aplicó
Pruebas unitarias (`pytest`, 11 pruebas)	Lógica de transformación: coma decimal, `Ip`, esquema, deduplicación, Winkler
Ejecución real en la plataforma con captura fechada	Cada notebook y cada ejecución del Job (E-06 a E-26)
14 controles de calidad automáticos	Cada ejecución: unicidad, origen real, rango, conciliación bronze → silver/quarantine
Comprobación independiente del resultado	`SHOW GRANTS` tras el GRANT de permisos (INC-06)
Contraste con fuente oficial	Calificaciones DOCa (web del Consejo Regulador), Winkler (informe de índices bioclimáticos de AEMET)
Comparación del árbol sintáctico (AST)	Comentarios de los notebooks: el código ejecutable no cambió
Revisión visual del documento renderizado	Cada versión de la memoria

6. Dónde se equivocó o no llegó la IA

Es la parte más útil para valorar el uso de la IA: muestra que las salidas no se aceptaron sin comprobar.

Caso	Qué pasó	Cómo se detectó y resolvió
INC-06 · Permisos de la app	El GRANT propuesto por código se ejecutó **sin error pero sin efecto**: el identificador del *service principal* no era el correcto	`SHOW GRANTS` vacío; la autora concedió el permiso desde Catalog Explorer con el App ID correcto
INC-03 · Librería sin reinicio	El notebook no reiniciaba Python tras `%pip`	Aviso en la primera ejecución real; se añadió `restartPython()`
INC-02 · Límite de 8 MiB	No se anticipó el corte de respuestas de Free Edition	Error en la descarga de MITECO; descarga por tramos `Range`
INC-05 · Despliegue de la app	Se asumió que la app podría leer un repositorio privado	Error "no credential"; decisión de hacer público el repo tras revisar que no tiene secretos (D-18)
Valores de Winkler	Salían más altos que las referencias clásicas de Rioja	Se contrastó con AEMET en lugar de aceptarlos o "corregirlos" sin base
Linaje (D-17)	Los pasos con pandas no aparecen en el linaje de Unity Catalog	Detectado al revisar el linaje; declarado como límite

7. Reparto de papeles

La IA	La autora
Diagnóstico del código heredado	Elegir el caso, el alcance y las fuentes
Código del pipeline, pruebas, app y gobierno	Ejecutar en Databricks, crear el Job, la app y los permisos
Búsqueda y lectura de fuentes públicas	Validar los resultados y decidir qué se acepta
Borradores de documentación y memoria	Revisar, corregir y aportar su voz
Proponer soluciones a las incidencias	Detectar las incidencias en la plataforma y aplicar la solución

8. Skill propia: `pipeline-datos-controlado`

El método seguido en este TFM se ha empaquetado como una skill reutilizable (`skills/pipeline-datos-controlado/SKILL.md`), para aplicarlo en otros proyectos sin volver a explicarlo a la IA.

Contenido	Origen en el TFM
6 principios no negociables	Reglas de `CLAUDE.md` y hallazgos del diagnóstico
9 fases (diagnóstico → documentación)	Fases F0–F8 del plan del TFM
Catálogo de controles críticos y avisos	Notebook `03_quality_checks`
Cómo trabajar con IA en el flujo	Guía del TFM (§8) y este documento
Notas de Databricks Free Edition	Incidencias INC-02, INC-03, INC-05, INC-06 y decisión D-17
Checklist de cierre	Guía del TFM (§10)

Es el principal resultado reutilizable del trabajo con IA: la experiencia del proyecto queda como instrucción que cualquier sesión futura puede cargar.

C · Registro de decisiones · TFM Embalses

Cada decisión con su motivo y su evidencia. Fuente de las secciones 2–3 de la memoria.

#	Fecha	Decisión	Motivo	Evidencia / estado
D-01	24/10	Vía caso, proyecto propio, sobre el pipeline de embalses de agosto	Ya existe la fuente y la arquitectura; la guía pide centrarse en normalización, calidad, gobierno y operación	Guía §2
D-02	24/10	Partir del diagnóstico F0 como punto de partida del caso	Documenta el estado heredado; cada hallazgo se convierte en mejora con evidencia de antes y después	`diagnostico.md`, IA-001
D-03	24/10	**Caso del vino:** "condiciones hídricas y climáticas de la campaña en La Rioja frente a añadas anteriores"	Pregunta de negocio clara con fuentes reales; elimina la mezcla Ebro/Tajo (hallazgo 9)	Decisión de Patri
D-04	24/10	Fuentes núcleo: **AEMET** (estación de Logroño, diaria) y **MITECO** (embalses del Ebro, histórico desde 1988 y semanal). **DOCa Rioja** como dato de referencia en CSV versionado	Son las únicas fuentes reales y operables; la DOCa cambia una vez al año	Conectividad comprobada el 24/10 (captura)
D-05	24/10	Fuera: SAIH Ebro, Canal de Isabel II, MAPA	URLs sin verificar y sin relación con el vino	Límite declarado
D-06	24/10	Sustituir los modelos 04–06 por un **indicador de campaña vitícola**: lluvia acumulada, grados-día (Winkler) y nivel de embalses del Ebro, contrastado de forma descriptiva con la calificación DOCa	Explicable y verificable; los modelos no entrenaban con los datos disponibles y la guía no puntúa el modelado	Decisión de Patri
D-07	24/10	Dashboard en **Streamlit como Databricks App**, con una pestaña de negocio y otra de salud del pipeline	Código en el repo (reproducible), datos en vivo y evidencia de operación	Free Edition: máx. 3 apps, se paran a las 24 h
D-08	24/10	Repositorio en **GitHub** (cuenta de Patri), conectado a Databricks	Requisito de repositorio reproducible	Hecho: github.com/PatriciaL/tfm-embalses, Git folder en Databricks
D-09	24/10	Ingesta dentro de Databricks (sin GitHub Actions)	Prueba de conectividad: AEMET y MITECO responden desde Free Edition	Captura `2026-10-24_conectividad_fuentes`
D-10	24/10	Estación AEMET **9170 · Logroño Aeropuerto** como referencia climática	Estación principal de La Rioja, en el valle del Ebro y en zona de viñedo; el 9170X heredado no existe	Inventario AEMET (E-03)
D-11	24/10	Descarga de MITECO por tramos HTTP Range de 4 MiB	Free Edition corta las respuestas a 8 MiB; el servidor admite Range	INC-02, E-03
D-12	24/10	MITECO: usar la tabla `T_Datos Embalses 1988-2026` filtrada por cuenca (AMBITO_NOMBRE = Ebro); volumen = AGUA_ACTUAL, capacidad = AGUA_TOTAL. Carga histórica completa una vez y después incremental por FECHA	Datos reales y semanales hasta el 20/10/2026; la próxima actualización (~27/10) cae dentro del plazo del TFM y servirá como carga real observada	E-05
D-13	24/10	Normalizar la coma decimal en silver para MITECO y AEMET	Confirmado con datos reales: ambas fuentes usan coma decimal (hallazgo 5)	E-05
D-14	24/10	Referencia DOCa: tabla oficial del Consejo Regulador (2001–2025) con columna `tipo_fuente`; 2000 de fuente secundaria, marcada	Trazabilidad del dato de referencia; el CSV de ejemplo heredado tenía 6 de 10 añadas mal	IA-003
D-15	24/10	Filtro de cuenca: AMBITO_NOMBRE = "Ebro" (84 embalses)	La lista completa de ámbitos de MITECO confirma el nombre exacto y que no hay otro ámbito que lo contenga	E-06
D-16	24/10	Job diario `tfm_embalses_diario` a las 07:37, 4 tareas en cadena con "All succeeded"	Operación desatendida y fechada; si falla un paso no se publica nada parcial	E-16
D-17	24/10	Aceptar como límite que el linaje automático de Unity Catalog no enlaza tablas en los pasos con pandas (silver y campaña)	Reescribir esos pasos en Spark no compensa con el plazo; la trazabilidad por fila (_source, _ingest_ts, _run_id) y ops.run_log cubren el requisito	E-20
D-18	24/10	Repositorio GitHub **público**	La app necesita leer el código; sin secretos en el repo (revisado); el tribunal puede acceder sin permisos	INC-05

Abiertas

- Leer las 723.842 filas con access-parser es lento: valorar filtrar por cuenca antes de pasar a Spark.

D · Índice de evidencias · TFM Embalses

Cada captura se guarda en Drive › TFM Embalses › 03_Evidencias_capturas con el nombre indicado. El pie responde a lo que pide la guía (§5): qué se ve, qué demuestra y en qué fecha o ejecución se obtuvo.

#	Archivo	Fecha	Pie	Sección de la memoria
E-01	`2026-10-24_conectividad_fuentes.png`	24/10/2026 18:00	Prueba de conectividad desde Databricks Free Edition: los dominios de AEMET y MITECO son accesibles (MITECO 200; el 404 de AEMET corresponde a la raíz de la API, no a un bloqueo). Justifica mantener la ingesta dentro de Databricks (D-09).	2 · Fuentes
E-02	`2026-10-24_incidencia_aemet_estacion_miteco_8MiB.png`	24/10/2026 18:12	Primera prueba de descarga real. AEMET responde autenticado pero sin datos para la estación 9170X heredada del notebook original; la descarga del histórico de MITECO se corta a los 8.388.608 bytes (8 MiB) de unos 10,4 MB. Se registran como incidencias INC-01 e INC-02.	5 · Operación
E-03	`2026-10-24_resolucion_aemet_estaciones_miteco_tramos.png`	24/10/2026 18:27	Resolución de INC-01 e INC-02. El inventario oficial de AEMET muestra que el indicativo de Logroño Aeropuerto es **9170** (no 9170X). El histórico de MITECO se descarga completo (10.377.727 bytes) en tres tramos HTTP Range de 4 MiB (respuestas 206); el ZIP contiene `BD-Embalses.mdb` (Access).	5 · Operación
E-04	`2026-10-24_dependencia_access_parser.png`	24/10/2026 18:29	Instalación de `access-parser` 0.0.6 para leer el histórico de MITECO en formato Access (.mdb). Databricks la añade al entorno del notebook, de modo que la dependencia queda declarada para el Job y para reproducir el trabajo. *Apoyo: usar solo si falta espacio para justificar la reproducibilidad.*	3 · Método
E-05	`2026-10-24_fuentes_reales_miteco_mdb_aemet_9170.png`	24/10/2026 18:30	Primera lectura de datos reales. MITECO: tabla `T_Datos Embalses 1988-2026` con 723.842 filas (FECHA, AMBITO_NOMBRE, EMBALSE_NOMBRE, AGUA_TOTAL, AGUA_ACTUAL, ELECTRICO_FLAG), de 1987-10-06 a **2026-10-20**: el fichero se actualiza cada semana. Los volúmenes usan **coma decimal** ("308,00"), lo que confirma el hallazgo 5 del diagnóstico. AEMET 9170: estado 200, 20 días con lluvia y temperaturas, también con coma decimal.	2 · Fuentes
E-06	`2026-10-24_bronze_primera_carga_miteco.png`	24/10/2026 18:58	Primera carga real de bronze con el pipeline nuevo. MITECO: 723.842 filas leídas, **125.127 filas de la cuenca del Ebro** escritas (84 embalses), último dato 20/10/2026, sin columnas nuevas. La lista de ámbitos confirma que el nombre de la cuenca es exactamente "Ebro".	5 · Operación
E-07	`2026-10-24_bronze_primera_carga_fin.png`	24/10/2026 18:58	El notebook de bronze termina **sin errores** en la ejecución `manual-20261024-165849-779392`: ninguna fuente ha caído al fallback (ya no existe).	5 · Operación
E-08	`2026-10-24_bronze_primera_carga_aemet.png`	24/10/2026 18:58	Carga histórica de AEMET (estación 9170) en 55 tramos de 180 días: **9.790 registros diarios** del 01/01/2000 al 24/10/2026, en unos 4 minutos. El control de frescura de silver muestra que el último día publicado es el 21/10/2026 (3 días de retraso): de los 9.791 días del periodo faltan 1 en origen. AEMET devuelve 22 campos más de los esperados (humedad, presión, viento, sol…): se conservan en bronze, no se usan.	5 · Operación
E-09	`2026-10-24_silver_cuarentena_miteco.png`	24/10/2026 19:07	Silver de embalses del Ebro: de 125.127 filas, **124.701 aceptadas**, **228 rechazadas** (capacidad no numérica o ≤ 0) y **198 en revisión** (volumen > capacidad). El 0,34 % va a cuarentena con su motivo; nada se descarta sin rastro (hallazgo 4). Con el código heredado, la coma decimal habría convertido en nulo todos los volúmenes y la validación los habría eliminado en silencio.	4 · Calidad
E-10	`2026-10-24_silver_cuarentena_aemet.png`	24/10/2026 19:07	Silver de clima de Logroño: de 9.790 días, **9.778 aceptados**, **11 rechazados** (temperatura media no numérica) y **1 en revisión** (precipitación "Acum", acumulada de varios días). Sin duplicados tras la deduplicación.	4 · Calidad
E-11	`2026-10-24_calidad_controles_criticos.png`	24/10/2026 19:11	Primera ejecución de los 9 controles críticos: unicidad de claves, ausencia de datos sintéticos, % de capacidad en rango, silver no vacía y **conciliación bronze → silver + quarantine con 0 claves perdidas** en ambas fuentes. Todos superados.	4 · Calidad
E-12	`2026-10-24_calidad_avisos.png`	24/10/2026 19:11	Avisos: frescura MITECO 4 días (último dato 20/10), frescura AEMET 3 días (21/10), cuarentena 0,34 % en embalses y 0,12 % en clima, variación semanal de la reserva del Ebro 0,5 puntos. Todos dentro de umbral.	4 · Calidad
E-13	`2026-10-24_calidad_resumen.png`	24/10/2026 19:11	Resumen: 14 controles, ningún crítico fallido, ningún aviso. Los resultados quedan en `ops.quality_results`; si un crítico fallara, el notebook terminaría en error y gold no se publicaría.	4 · Calidad
E-14	`2026-10-24_gold_campana_vitivinicola.png`	24/10/2026 19:15	Indicador de campaña (abril–octubre), últimos 5 años: lluvia, grados-día de Winkler, completitud, reserva media del Ebro y calificación DOCa. 2026 aparece como campaña en curso (95,3 % de días con dato) y sin calificación, que se publica en primavera. 39 campañas en total (reserva desde 1988; clima desde 2000).	6 · Resultados
E-15	`2026-10-24_gold_kpis.png`	24/10/2026 19:15	KPIs de cabecera: reserva del Ebro **44,94 %** (semana del 20/10/2026), −0,5 puntos frente a la semana anterior y **−7,98 puntos** frente a la misma semana de 2025; lluvia de campaña 201,7 mm y Winkler 2.377 grados-día en Logroño; 0,2 horas desde la última carga de MITECO con datos nuevos (calculado desde `ops.run_log`, ya no es un valor de relleno).	6 · Resultados
E-16	`2026-10-24_job_tfm_embalses_diario.png`	24/10/2026 19:26	Job `tfm_embalses_diario` en Databricks: 4 tareas encadenadas (bronze → silver → calidad → gold, cada una solo si la anterior termina bien), cómputo serverless, parámetro `run_id = {{job.run_id}}` y programación diaria a las 07:37 (Europe/Madrid). Es lo que genera las ejecuciones fechadas de la operación.	5 · Operación
E-17	`2026-10-24_job_primera_ejecucion.png`	24/10/2026 19:31	Primera ejecución del Job lanzada a mano: **las 4 tareas terminan bien en 6 min 15 s**. Las dos ejecuciones canceladas (UserCanceled) son **cancelaciones manuales** de lanzamientos duplicados, confirmadas por la autora: no son incidencias. Performance optimized desactivado para no agotar la cuota diaria de Free Edition.	5 · Operación
E-18	`2026-10-24_gobierno_etiquetas_comentarios.png`	24/10/2026 19:38	Notebook de gobierno: las **14 tablas** del catálogo `tfm_embalses` (bronze, silver, quarantine, gold, ops y ref) reciben comentario descriptivo y etiquetas de clasificación (`clasificacion = publico`, `datos_personales = no`, capa, fuente y proyecto).	4 · Gobierno
E-19	`2026-10-24_gobierno_tabla_gold_tags.png`	24/10/2026 19:42	Catalog Explorer, tabla `gold.campana_vitivinicola`: descripción de la tabla, comentarios de columna (definición del índice de Winkler y de la completitud) y etiquetas `capa: gold`, `clasificacion: publico`, `datos_personales: no`, `fuente: AEMET+MITECO+DOCa` y `proyecto: tfm_embalses`.	4 · Gobierno
E-20	`2026-10-24_gobierno_linaje_campana.png`	24/10/2026 19:43	Linaje de `gold.campana_vitivinicola` en Unity Catalog: registra quién la escribe (notebook `04_gold_publish` y Job `tfm_embalses_diario`, hace 11 minutos), pero **no las tablas de origen**. Límite identificado: los pasos que pasan por pandas (`toPandas` → `createDataFrame`) rompen el linaje automático entre tablas. Se compensa con la trazabilidad por fila (`_source`, `_ingest_ts`, `_run_id`) y con `ops.run_log`.	4 · Gobierno
E-21	`2026-10-24_gobierno_linaje_reserva.png`	24/10/2026 19:45	Linaje de `gold.reserva_ebro_semanal`: Unity Catalog enlaza automáticamente la tabla de origen `silver.embalses_ebro` (11 columnas, con `_source` e `_ingest_ts`) con la tabla gold (5 columnas). Contraste con E-20: donde la transformación es SQL/Spark, el linaje entre tablas sí queda registrado.	4 · Gobierno
E-22	`2026-10-24_gobierno_permisos_app.png`	24/10/2026 20:00	Exposición mínima: se concede al service principal de la app (`f5ea971d-…-6849aee6e044`) `USE CATALOG` en `tfm_embalses` y `USE SCHEMA` + `SELECT` **solo** en `gold`, `ops` y `ref`. Bronze y quarantine quedan fuera de su alcance.	4 · Gobierno
E-23	`2026-10-24_incidencia_app_credencial_git.png`	24/10/2026 20:04	Primer despliegue de la app fallido: *invalid Git credential*, el repositorio es privado y la app no tiene credencial de Git asignada (INC-05).	5 · Operación
E-24	`2026-10-24_app_despliegue_ok.png`	24/10/2026 23:48	Resolución de INC-05: con el repositorio público, el despliegue del commit `c9c3f70` completa los 6 pasos en 15 s (código descargado, especificación cargada, paquetes instalados, app construida y arrancada). Debajo queda el intento fallido anterior como rastro.	5 · Operación

#	Archivo	Fecha	Pie	Sección de la memoria
E-25	`2026-10-25_gobierno_grants_catalogo.png`	25/10/2026 00:00	Verificación con `SHOW GRANTS`: la identidad de la app en Unity Catalog es `e8c5141f-1f38-…` (el *App ID*), ahora con `USE CATALOG` en `tfm_embalses`. Explica INC-06: el GRANT anterior usó otro identificador (`f5ea971d-…`) y no dejó permiso efectivo.	4 · Gobierno
E-26	`2026-10-25_gobierno_gold_ops.png`	25/10/2026 00:01	`SHOW GRANTS` en los esquemas `gold` y `ops`: la app (`e8c5141f-…`) tiene `USE SCHEMA` y `SELECT`, lo justo para leer los indicadores y la salud del pipeline.	4 · Gobierno
E-27	`2026-10-25_job_ejecucion_programada.png`	25/10/2026 07:37	Primera ejecución **desatendida** del Job `tfm_embalses_diario`: lanzada «By scheduler» a las 07:37 (run 877688566878390), 7 min 23 s, las 4 tareas (bronze, silver, calidad, gold) correctas. Debajo, el historial del 24/10: una ejecución manual correcta y dos canceladas a mano durante las pruebas (UserCanceled).	5 · Operación
E-28	`2026-10-25_app_salud_ejecuciones.png`	25/10/2026 ~10:00 (ejecución de las 07:37)	Pestaña «Salud del pipeline» tras reiniciar la app (se para a las 24 h en Free Edition): la ejecución programada `877688566878390` aparece arriba con resultado OK; AEMET `OK` y MITECO `OK_SIN_CAMBIOS` (la huella del fichero no cambió, no se recargan ni duplican filas). Horas en UTC.	5 · Operación
E-29	`2026-10-25_app_salud_controles.png`	25/10/2026 (ejecución de las 07:37)	Controles de la ejecución programada: 14 controles, 0 críticos fallidos, 0 avisos. Frescura AEMET 4 días (último dato 21/10) y MITECO 5 días (20/10); cuarentena 12 de 9.790 días de clima (0,12 %) y 426 de 125.127 lecturas de embalses (0,34 %); conciliación 0 en ambas fuentes.	4 · Calidad / 5 · Operación
E-30	`2026-10-28_job_ejecuciones_programadas.png`	28/10/2026 18:45	Cuatro ejecuciones **programadas consecutivas** del Job, todas correctas y lanzadas «By scheduler» a las 07:37: 25/10 (7 min 23 s), 26/10 (6 min 5 s), 27/10 (6 min 28 s) y 28/10 (6 min 57 s). El programador respeta la zona Europe/Madrid tras el cambio de hora del 25/10. Panel lateral: linaje del Job con 9 tablas de origen y 13 de destino.	5 · Operación
E-31	`2026-10-28_app_salud_ejecuciones_miteco_nuevo.png`	28/10/2026 18:50	**Primera carga real con datos nuevos de MITECO.** En la ejecución del 28/10 (`499273492547825`) MITECO pasa a `OK`: la huella del fichero cambió. En las del 25, 26 y 27/10 seguía `OK_SIN_CAMBIOS`, sin recargar nada. Confirma lo previsto en D-12. Horas en UTC.	5 · Operación
E-32	`2026-10-28_app_salud_controles.png`	28/10/2026 (ejecución de las 07:37)	Controles tras la carga nueva: 14/14 superados. Frescura MITECO 1 día (último dato 27/10, antes 5) y AEMET 4 días (24/10). Silver embalses 124.777 lecturas (+76 frente a E-29) con unicidad 0, aunque bronze recibió de nuevo el histórico: la deduplicación por ingesta más reciente funciona. Conciliación 0; cuarentena estable (426 de 125.203 y 12 de 9.793); salto semanal 0,03 puntos.	4 · Calidad / 5 · Operación

Incidencias

#	Fecha	Incidencia	Causa	Resolución	Estado
INC-01	24/10	AEMET no devuelve datos para la estación 9170X	Probable indicativo erróneo heredado del notebook original	Inventario oficial: el indicativo correcto es 9170 (Logroño Aeropuerto). Evidencia E-03	Resuelta 24/10
INC-02	24/10	La descarga de BD-Embalses.zip se corta a los 8 MiB	Probable límite de tamaño de respuesta en la salida de Free Edition	Descarga por tramos HTTP Range de 4 MiB: el servidor los acepta (206) y el ZIP llega íntegro. Evidencia E-03	Resuelta 24/10
INC-03	24/10	Aviso de Databricks: reiniciar Python tras instalar `access-parser`	`%pip` instala la librería pero la sesión no la recarga sola	Se añade `dbutils.library.restartPython()` tras la instalación (commit 5f0d84b). En la ejecución manual no llegó a bloquear	Resuelta 24/10
INC-04	24/10	`GRANT` falla con PRINCIPAL_DOES_NOT_EXIST	Se usó el nombre visible del service principal (`app-2o21fx tfm-embalses-dashboard`) en lugar de su identificador	Usar el UUID del service principal (pestaña Authorization de la app). Evidencia E-22	Resuelta 24/10
INC-05	24/10	La app no puede descargar el código del repositorio	Repositorio privado sin credencial de Git asignada a la app	Repositorio hecho público (revisado antes: sin secretos; la key de AEMET está en el secret scope). Además facilita la revisión del TFM. Evidencias E-23 y E-24	Resuelta 24/10
INC-06	24/10	La app desplegada no puede leer datos: INSUFFICIENT_PERMISSIONS (sin USE CATALOG)	El GRANT por código usó un identificador (`f5ea971d-…`) distinto del que Unity Catalog usa para la app (`e8c5141f-…`, el App ID); el comando no dio error pero `SHOW GRANTS` estaba vacío	Permisos concedidos desde Catalog Explorer buscando la app por nombre y verificados con `SHOW GRANTS`. Documentado en `05_governance` y `app/README.md`. Evidencia E-25	Resuelta 25/10

E · F0 · Diagnóstico del pipeline de embalses

TFM Jxpert IA · Track Data · Revisión del 24/10/2026 sobre el export `kinedrik_caso_practico_embalses.zip` (notebooks de agosto de 2026). Método: lectura del código y de los CSV de `sample_data/`. **No se ha ejecutado nada**: lo que depende de la ejecución está marcado como *a verificar*.

---

1. Qué hay

Pieza	Qué hace	Estado
`00_setup_secrets`	Guarda la API key de AEMET en el secret scope `caso-practico`	✅ Correcto: la key no queda en el código
`00b_setup_catalog`	Crea el catálogo `embalses_caso_practico` y los esquemas `bronze`, `silver`, `gold`	✅ Correcto
`01_bronze_ingest`	Ingesta de 6 fuentes en `bronze.*`, en modo append, con `_ingest_date` y `_source`	⚠️ Ver hallazgos 1–3
`02_silver_transform`	Unifica los embalses en `silver.embalses` (embalse, fecha, cuenca, volumen, capacidad, %), valida rangos y copia lluvia, añadas y producciones	⚠️ Ver hallazgos 4–8
`03_gold_aggregate`	`gold.capacidad_embalses` (última lectura), `gold.indice_estres_hidrico` (año × cuenca) y `gold.kpis_proyecto` (4 KPIs)	⚠️ Ver hallazgos 9–11
`04–06_model_*`	XGBoost de nivel de embalse, clasificador agua→añada de Rioja y regresión agua→huerta, con MLflow	⏸️ Fuera del núcleo del TFM (hallazgo 12)
`sample_data/`	5 CSV de ejemplo (SAIH, MITECO, Canal, DOCa, MAPA)	Datos inventados de julio de 2026

Lo que **no** está en el export: definición del Job, README, repositorio Git, tests, tabla de log de ejecuciones, tabla de resultados de calidad, cuarentena, y la "skill" `query_gold.py` y el Power BI que mencionan los notebooks.

2. Hallazgos

Fuentes (lo más grave)

1. **El pipeline funciona casi siempre con datos de ejemplo, sin decirlo.** SAIH Ebro, MITECO, Canal de Isabel II y MAPA intentan URLs marcadas `# VERIFICAR`, que con toda probabilidad no existen. Si fallan, cargan el CSV de `sample_data/`, y solo lo dejan escrito en un `print`. DOCa Rioja lee siempre el CSV. En la tabla bronze no queda ninguna marca que distinga un dato real de uno de ejemplo. *A verificar en la primera ejecución.*
2. **AEMET inventa datos cuando falla.** Si la API no responde, se inserta una lectura sintética de **0,0 mm de lluvia**. Ese cero llega a `silver.lluvia` y al índice de estrés hídrico como si fuera una observación real. Es el error de calidad más serio del código.
3. **Cada ejecución vuelve a cargar los mismos CSV de ejemplo** con una `_ingest_date` nueva. Bronze crece con copias idénticas, y operar varios días no aporta datos nuevos.

Silver

4. **Las filas que no pasan la validación se descartan sin rastro.** `validate()` las filtra y solo imprime cuántas son. No existe cuarentena ni registro del motivo, y la guía pide separar aceptados, en revisión y rechazados.
5. **No se tratan los decimales con coma.** `cast(DoubleType)` sobre "1.319,5" devuelve `null`, y la fila se pierde en la validación sin ningún aviso. **Confirmado el 24/10** con los datos reales: MITECO ("308,00") y AEMET ("13,2") usan coma decimal (evidencia E-05).
6. **La deduplicación es arbitraria.** `dropDuplicates(["embalse","fecha"])` se queda con una fila cualquiera:
   - en SAIH, que es horario, la del día puede ser la de cualquier hora;
   - El Atazar, Santillana y Pinilla llegan a la vez por MITECO y por Canal con la misma fecha, y gana una fuente al azar;
   - las copias de bronze de distintos días de ingesta no tienen criterio de "la más reciente".
7. **`silver.lluvia` no es idempotente.** Se escribe en modo append sin deduplicar, así que cada reejecución duplica la lluvia y distorsiona la lluvia acumulada.
8. **Un cambio de nombre de columna en origen rompe el pipeline** con un error genérico. No hay comprobación de esquema esperado.

Gold

9. **El índice de estrés hídrico mezcla cuencas.** La lluvia es de una sola estación (Logroño, Ebro) y se une solo por año, de modo que se aplica también a la cuenca del Tajo. Además, con un solo año de datos la normalización min–max devuelve 0,5 constante.
10. **`estres_hidrico_actual` está mal calculado.** El `orderBy(...).agg(avg)` hace la media de todos los años, no del último.
11. **Hay KPIs de relleno.** `horas_desde_ultima_ejecucion` vale siempre 0,0 y `mae_modelo_nivel` vale -1 hasta que corre el notebook 04.

Modelos

12. Con los datos de ejemplo, los modelos 05 y 06 no encuentran años comunes (el índice solo tiene 2026 y las añadas van de 2015 a 2024) y no entrenan; el 04 tiene muy pocas filas. Los propios notebooks lo avisan. Para el TFM no aportan evidencia de calidad ni de operación.

3. Lo que está bien y se aprovecha

- Arquitectura medallion sobre Unity Catalog con tablas Delta registradas, consultables por SQL y por el dashboard.
- Bronze en append con fecha de ingesta y fuente: base correcta para la trazabilidad y para demostrar cargas sucesivas.
- Secretos fuera del código.
- Parámetro `run_date` y rutas absolutas, ya pensados para ejecutarse como Job.
- Documentación honesta en los propios notebooks sobre qué está verificado y qué no.

4. Fuente real disponible

MITECO publica en la página del Boletín Hidrológico un histórico descargable (`BD-Embalses.zip`, en Excel) con la capacidad y la reserva semanal de **cada embalse peninsular de más de 5 hm³ desde 1988**, más un documento de modelo de datos. Está marcado como provisional y sin validar. Fuente: MITECO · Boletín hidrológico.

Encaja con el TFM: es real, se actualiza cada semana, cubre todas las cuencas y su propia advertencia de datos sin validar justifica la capa de calidad. *A verificar en F3:* que la descarga funciona desde Databricks Free Edition (salida a internet) y la estructura real del Excel.

5. Huecos frente a la guía del TFM

Requisito de la guía	Estado actual
Normalización trazable	Parcial: sin coma decimal, sin control de esquema, deduplicación arbitraria
Aceptados / revisión / rechazados	❌ No existe
Controles repetibles con resultado registrado	❌ Solo un filtro con `print`
Gobierno (clasificación, exposición, linaje)	❌ Nada explícito; los datos son públicos y sin datos personales

Requisito de la guía	Estado actual
Operación: ejecuciones fechadas, logs e incidencias	❌ Sin Job versionado ni tabla de ejecuciones
Repositorio reproducible	❌ Solo existe en el workspace
Registro de IA y ROI	❌ Por empezar

6. Propuesta de alcance (para decidir en F1)

1. **Núcleo:** MITECO real (histórico y actualización semanal) más AEMET real. El resto de fuentes quedan como límite declarado o se retiran.
2. **Primeras correcciones:** eliminar el fallback silencioso y el dato sintético de AEMET (una fuente que falla genera una incidencia, no datos), marcar el origen de cada fila, coma decimal, deduplicación con criterio, lluvia idempotente y control de esquema.
3. **Capas nuevas:** `quarantine`, `ops.run_log`, `ops.quality_results` y parada de la publicación en gold si falla una regla crítica.
4. **Gold:** corregir el KPI de estrés, calcular las horas desde la última ejecución a partir de `run_log` y limitar el índice a la cuenca del Ebro, donde está la estación de lluvia, o declararlo como límite.
5. **Modelos 04–06:** fuera del alcance, mencionados como trabajo previo.

> Los hallazgos 1, 2, 4 y 6 son buen material para la memoria: el diagnóstico de un pipeline heredado que "funcionaba" pero producía datos no verificables es justo lo que la guía pide demostrar.